

Proyecto Final

Pipeline Integral de Ciencia de Datos & IA

Entregables: Notebook Jupyter documentado y Presentación

Objetivo del Proyecto

Construir y defender un pipeline analítico y predictivo de principio a fin, partiendo de la ingesta y gobernanza de un conjunto de datos real descargado de Kaggle, realizando el diagnóstico exploratorio (EDA), el modelado supervisado con validación rigurosa, hasta la traducción de las métricas técnicas a impacto financiero.

Criterios de Selección del Dataset (Kaggle)

Cada equipo debe elegir y descargar un dataset público de Kaggle que cumpla con los siguientes requisitos mínimos:

- **Volumen:** Mínimo 1,000 registros y al menos 8 columnas (mezcla de variables numéricas y categóricas).
- **Naturaleza del problema:** Debe contener una variable objetivo (Y) clara para resolver un problema de Clasificación Binaria/Multiclase o de Regresión Numérica.
- **Ejemplos recomendados para búsqueda en Kaggle:**
 - *Telco Customer Churn* (Predicción de cancelación de clientes)
 - *Credit Card Fraud Detection* o *Bank Loan Approval* (Riesgo crediticio / Fraude)
 - *House Prices: Advanced Regression Techniques* (Estimación de precios inmobiliarios)
 - *Hospital Readmission / Healthcare Stroke Prediction* (Diagnóstico clínico preventivo)

Estructura Oficial del Entregable (Estructura del Notebook)

El notebook final debe estar dividido obligatoriamente en las siguientes 5 Fases del Pipeline:

Fase 1: Formulación del Problema y Gobernanza

1. Ficha Técnica del Negocio:

- Definir el objetivo operativo de la empresa.
- Especificar la variable dependiente (Y) con su respectiva unidad de medida o clases posibles.
- Justificar por qué es un problema de Clasificación o Regresión.

2. Estrategia de Gobernanza y Privacidad:

- Definir quiénes serían el *Data Owner* y *Data Steward* de esa información en la empresa.
- Identificar la presencia de un dato sensible (PII: nombres, identificadores) y programar una función en Python para anonimizarlo (Hashing SHA-256) o enmascararlo antes de enviarlo al modelo.

Fase 2: Auditoría de Calidad y Exploración Profunda - EDA

1. Evaluación de Dimensiones de Calidad:

- Reportar el porcentaje de nulos por columna (Complejidad) y justificar el método de imputación.
- Comprobar y eliminar duplicados (Unicidad).

2. Análisis Univariado y Bivariado:

- Calcular medidas de tendencia central, dispersión y evaluar la asimetría de la variable principal.
- Implementar una segmentación con `groupby()` o `pivot_table()` que responda a una pregunta estratégica de negocio.
- Generar una visualización comparativa (Matriz de Correlación *Heatmap*, *Violin Plot* o *Boxplot* condicional) aplicando paletas de color accesibles y atributos pre-atentivos.

Fase 3: Modelado Estadístico y Capacidad de Generalización

1. Entrenamiento y Validación Cruzada:

- Entrenar al menos dos modelos competidores (ej. Regresión Lineal vs. Ridge/Lasso; o Regresión Logística vs. Árbol de Decisión).
- Evaluar la estabilidad del modelo usando 5-Fold Cross-Validation sobre el conjunto de entrenamiento para evitar el sesgo de partición.

2. Diagnóstico de Complejidad:

- Identificar si el modelo sufre de Subajuste (Alto Sesgo) o Sobreajuste (Alta Varianza) comparando el error de *Train* vs. el error de *Test*.

Fase 4: Traducción a Impacto Financiero y Negocio

1. Evaluación de Desempeño:

- Para clasificación: Matriz de Confusión completa, Reporte de Clasificación (*Precision*, *Recall*) o Curva ROC-AUC.
- Para regresión: *MAE*, *MSE*

2. Traducción Monetaria del Error:

- Asignar valores monetarios hipotéticos razonables al error:
 - *En clasificación*: ¿Cuánto dinero pierde la empresa por un Falso Negativo (*FN*) vs. el costo de fricción de un Falso Positivo (*FP*)?
 - *En regresión*: ¿Cuánto cuesta en almacenamiento o desabasto fallar por $\pm X$ unidades en la predicción?
- Redactar un balance final estimando el ahorro o beneficio neto del modelo.

Fase 5: Comunicación Ética y Limitaciones

- Declarar abiertamente al menos dos limitaciones técnicas o sesgos potenciales presentes en el dataset que el Director de Tecnología debe conocer antes de desplegar el modelo en producción.